

O balanceamento refere-se à **distribuição das classes ou categorias** em uma **variável de interesse** dentro do conjunto de dados. Isso é especialmente importante em tarefas de aprendizado de máquina supervisionado, onde estamos interessados em prever ou classificar uma determinada classe ou categoria.

**O que é
balanceamento?**



IMPACTO

- **Impacto no desempenho do modelo:** Em muitos algoritmos de aprendizado de máquina, um conjunto de dados desbalanceado pode resultar em um modelo tendencioso ou enviesado em direção às classes majoritárias. Isso pode levar a uma baixa precisão na previsão das classes minoritárias, já que o modelo pode aprender menos sobre essas classes devido à sua menor representação no conjunto de dados.
- **Avaliação do desempenho:** Métricas de avaliação de desempenho, como precisão, sensibilidade, especificidade e F1-score, podem ser enganosas em conjuntos de dados desbalanceados. Um modelo pode ter uma alta precisão simplesmente prevendo a classe majoritária na maioria das vezes, mas isso não significa que o modelo está sendo útil na prática.
- **Custo de erro:** Em muitos casos, as classes podem ter custos de erro diferentes. Por exemplo, em um problema de detecção de fraudes, errar ao prever uma transação fraudulenta como legítima pode ter custos muito maiores do que errar ao prever uma transação legítima como fraudulenta. Se as classes estão desbalanceadas, os modelos podem não levar em consideração adequadamente esses custos diferenciais de erro.

TÉCNICA DE BALANCEAMENTO

UNDERSAMPLING

- Envolve a redução do número de instâncias da classe majoritária para equilibrar a distribuição das classes no conjunto de dados.
- A ideia é reduzir a quantidade de dados da classe majoritária para corresponder à quantidade de dados da classe minoritária.
- Isso pode ser feito selecionando aleatoriamente uma parte das instâncias da classe majoritária para remover do conjunto de dados.

OVERSAMPLING

- Envolve a criação de instâncias artificiais da classe minoritária para equilibrar a distribuição das classes no conjunto de dados.
- A ideia é aumentar a quantidade de dados da classe minoritária para corresponder à quantidade de dados da classe majoritária.
- Isso pode ser feito duplicando ou gerando novas instâncias da classe minoritária.

SMOTE

“Synthetic Minority Over-sampling Technique”.

É uma técnica usada para **lidar com conjuntos de dados desbalanceados**.

Isso significa que ele é usado quando há uma grande diferença na quantidade de exemplos entre diferentes categorias ou classes. O SMOTE funciona criando novos exemplos sintéticos da classe minoritária, para que haja um equilíbrio melhor entre as classes. Esses exemplos sintéticos são gerados com base nos exemplos já existentes na classe minoritária, de modo a não alterar drasticamente a natureza dos dados.

O fluxo do aprendizado Supervisionado

01.

TREINAMENTO

Durante esta etapa, alimentamos o algoritmo de aprendizado supervisionado com um conjunto de dados de treinamento, que inclui exemplos de entrada (características) e saída desejada (rótulos ou respostas corretas). O algoritmo usa esses exemplos para aprender como mapear as entradas para as saídas corretas.

02.

TESTE

Testamos o desempenho do algoritmo em um conjunto de dados separado, chamado conjunto de teste. Este conjunto contém exemplos com entradas, mas sem as saídas correspondentes. O algoritmo então faz previsões com base nas entradas e comparamos essas previsões com as respostas reais para avaliar sua precisão.

03.

AVALIAÇÃO

Nesta etapa, avaliamos o desempenho do algoritmo com base em métricas como precisão, recall e F1-score. Se o desempenho não atender às expectativas, podemos ajustar os parâmetros do algoritmo.

ATRIBUTOS CATEGÓRICOS

Imagine que você está tentando ensinar um robô a prever se uma fruta é uma maçã ou uma laranja com base em suas características, como cor, tamanho e textura. O robô adora fazer cálculos matemáticos, como média, máximo e mínimo, mas não entende palavras como "vermelho" ou "doce". Então, para ensinar o robô a fazer previsões, você precisa transformar essas características em números. Por exemplo, você pode representar a cor vermelha como 1, a cor laranja como 2 e assim por diante. Da mesma forma, você pode representar características como "doce" como 1 e "azedo" como 0.

Depois de transformar todas essas características em números, você pode alimentar esses dados ao robô, que agora pode usar seus cálculos matemáticos para aprender a distinguir entre maçãs e laranjas com base nos números.

TÉCNICA DE TRATAMENTO CATEGÓRICO

Label Encoder

- O Label Encoder é uma técnica usada para transformar valores de atributos categóricos em números.
- Ele atribui um número único a cada valor único na sua coluna categórica. Por exemplo, "maçã" pode ser representada pelo número 0, "laranja" pelo número 1 e "banana" pelo número 2.
- Dessa forma, o Label Encoder transforma suas características categóricas em valores numéricos que os modelos de aprendizado de máquina podem entender e processar.

One Hot Encoder

- É outra técnica usada para lidar com variáveis categóricas, mas funciona de forma um pouco diferente do Label Encoder.
- O One-Hot Encoder transforma cada valor único em uma categoria categórica em uma nova coluna binária. Cada coluna representa uma categoria e contém um valor binário (0 ou 1) que indica se a observação pertence ou não a essa categoria.

QUANDO UTILIZAR?

Label Encoder

- O Label Encoding é útil quando você tem uma variável categórica ordinal, ou seja, quando há uma ordem natural entre as categorias. Por exemplo, "baixo", "médio" e "alto".
- Atribui um número inteiro a cada categoria, codificando-as de forma sequencial. Por exemplo, "baixo" pode ser 0, "médio" 1 e "alto" 2.

One Hot Encoder

- One-Hot Encoding é mais apropriado quando não há ordem entre as categorias, ou quando você quer evitar que o algoritmo de aprendizado de máquina atribua pesos diferentes às categorias.
- Cria uma nova coluna binária para cada categoria, onde cada coluna representa uma categoria única e é marcada com 1 (quente) ou 0 (frio) para indicar a presença ou ausência da categoria na observação.

MULTICOLINEARIDADE

Multicolinearidade é um fenômeno que ocorre quando uma ou mais variáveis independentes em um modelo de regressão são altamente correlacionadas entre si.

Problemas causados pela multicolinearidade:

- **Coeficientes Instáveis:** Pequenas alterações nos dados podem levar a grandes variações nos coeficientes das variáveis independentes.
- **Significância Estatística Inflada ou Reduzida:** Pode tornar difícil determinar a importância de cada variável independente no modelo, pois os coeficientes podem ser altamente dependentes uns dos outros.
- **Redução da Precisão:** A precisão dos coeficientes estimados pode ser reduzida, tornando as previsões menos confiáveis.
- **Dificuldade de Interpretação:** A interpretação dos coeficientes das variáveis se torna difícil, pois é complicado entender a contribuição individual de cada variável para o resultado.