

Rafael A.R da Rosa

Prática do Módulo: Na prática do dia a dia: O pós-modelo do curso Profissão: Cientista de Dados.

Modelo escolhido: Árvore de decisão

Coleta de Dados

Esta etapa é crucial porque nenhum modelo pode existir sem dados representativos. Aqui, reunimos informações relevantes para o problema que queremos resolver. Essas informações podem vir de diversas fontes, como bancos de dados internos, planilhas, APIs, sensores, redes sociais, entre outros. Um desafio comum é garantir que os dados estejam completos, atualizados e livre de vieses que possam comprometer a imparcialidade do modelo. Por exemplo, ao prever cancelamento de serviço, devemos coletar dados variáveis como idade, tempo de contrato e uso do serviço.

Preparação dos Dados

Aqui transformamos os dados "crus" em uma forma útil para o modelo. Isso envolve limpar dados duplicados ou errados, tratar valores nulos, e transformar variáveis para uma forma adequada ao algoritmo, como codificar variáveis categóricas. Também criamos novas características relevantes (feature engineering), como extrair dia da semana de uma data. Além disso, dividimos os dados em partes para treino e teste para evitar que o modelo memorize em vez de aprender. Ferramentas como Pandas e Scikit-learn tornam essa etapa mais eficiente.

Escolha do Modelo

É o momento de decidir qual algoritmo utilizar. Árvore de decisão é uma boa escolha inicial por sua interpretabilidade e capacidade de lidar tanto com dados numéricos quanto categóricos, sem exigir normalização. Para problemas mais complexos, outros modelos podem oferecer maior precisão, porém com menor simplicidade para interpretação. A escolha depende da complexidade do problema, da interpretação desejada e disponibilidade de dados.

Treinamento do Modelo

Nesta fase, o algoritmo constrói a árvore dividindo os dados segundo critérios (exemplo: índice de Gini ou entropia), criando regras sequenciais do tipo "Se idade < 30, então...". É importante evitar o overfitting, quando a árvore aprende demais os detalhes do conjunto de treino e perde capacidade de generalização. Ou seja, a árvore não deve se tornar excessivamente profunda.

Avaliação do Modelo

Depois de treinado, testamos o modelo com dados que ele nunca viu. Usamos métricas para verificar sua qualidade, por exemplo, acurácia, precisão e recall para classificação. Em

situações com classes desbalanceadas, métricas como F1-score são importantes para equilibrar precisão e sensibilidade. Visualizar a própria árvore pode ajudar a entender e explicar decisões.

Ajuste e Otimização

Aqui buscamos aprimorar o desempenho do modelo ajustando os hiperparâmetros como profundidade máxima da árvore ou critério de divisão. Para isso, utilizamos técnicas como Grid Search (testar sistematicamente combinações), Random Search (testes aleatórios) por exemplo. O objetivo é melhorar a performance sem perder a capacidade de generalizar para dados novos.

Implantação e Monitoramento

Por fim, o modelo é integrado a sistemas reais, podendo se tornar uma API, dashboard ou aplicação. O monitoramento contínuo é essencial para garantir que o modelo continue performando bem ao longo do tempo, detectando mudanças nos dados (drift) e re-treinando quando necessário. Ferramentas como Docker, Flask, MLflow e Airflow auxiliam no processo.