



Redução de Dimensionalidade

Reduzir o número de variáveis em um modelo sem perder informação essencial.

Dimensionalidade: Refere-se ao número de características ou variáveis em um conjunto de dados. Em um espaço de alta dimensionalidade, a complexidade dos dados aumenta e a visualização se torna mais difícil.



Curse of Dimensionality:

A maldição da dimensionalidade é um conceito que descreve os desafios que surgem quando se trabalha com dados que possuem um grande número de dimensões, ou seja, variáveis.

Imagine que você tem um conjunto de dados com apenas duas variáveis, como altura e peso.

1. Espaço 2D:

- Com apenas essas duas variáveis, você pode visualizar os dados em um gráfico de dispersão, onde cada ponto representa uma pessoa.
- Se houver padrões, como dois grupos distintos (por exemplo, pessoas com altura e peso semelhantes e pessoas com alturas e pesos diferentes), eles são relativamente fáceis de identificar visualmente.

Agora, considere que você tem um conjunto de dados com 10 variáveis.

2. Espaço 10D:

- Com 10 variáveis, os dados existem em um espaço de 10 dimensões. Cada ponto agora é definido por 10 características, como altura, peso, idade, renda, número de filhos, entre outros.

Curse of Dimensionality:

A maldição da dimensionalidade é um conceito que descreve os desafios que surgem quando se trabalha com dados que possuem um grande número de dimensões, ou seja, variáveis.

- **Espaço Exponencial:** À medida que adicionamos mais variáveis, o volume do espaço de dados aumenta exponencialmente. Com 10 dimensões, o espaço é muito maior do que em 2 dimensões. Isso significa que os pontos de dados estão mais espalhados e a densidade de pontos é muito baixa.
 - **Distância Similar:** Em um espaço de alta dimensionalidade, a diferença entre a distância de qualquer par de pontos torna-se pequena e menos significativa. Todos os pontos parecem estar a distâncias semelhantes uns dos outros, o que dificulta a identificação de padrões baseados em distância.
- **Visualização:** Não é possível visualizar diretamente um espaço com 10 dimensões. Isso torna a análise e a interpretação dos dados muito mais complexas.

A maldição da dimensionalidade ocorre quando aumentar o número de variáveis em um conjunto de dados torna a análise e a modelagem mais desafiadoras. O volume do espaço aumenta exponencialmente, os pontos de dados ficam mais dispersos, e as distâncias entre os pontos se tornam menos significativas. Isso pode levar a dificuldades na visualização, interpretação e construção de modelos, além de aumentar o risco de sobreajuste.





Técnicas para Lidar com a Maldição

Uma das técnicas mais eficazes para lidar com a maldição da dimensionalidade é a Análise de Componentes Principais (PCA, do inglês Principal Component Analysis). O PCA é uma técnica de redução de dimensionalidade que ajuda a simplificar conjuntos de dados com muitas variáveis, mantendo o máximo de informação possível.

PCA trabalha identificando as direções (ou componentes principais) em que os dados variam mais. Essas direções são as combinações lineares das variáveis originais que capturam a maior variação no conjunto de dados.