


PCA

Principal Component Analysis




É uma técnica estatística usada para reduzir a dimensionalidade de um conjunto de dados, ao mesmo tempo que preserva a maior parte da variação presente nos dados originais.

PCA é um procedimento matemático que usa uma transformação ortogonal para converter um conjunto de variáveis possivelmente correlacionadas em um conjunto menor de variáveis não correlacionadas, conhecidas como componentes principais.



PCA



Principal Component Analysis



PCA

Principal Component Analysis



Suponha que você esteja estudando diferentes características de frutas, como peso, cor, doçura, tamanho, etc. Cada uma dessas características representa uma dimensão diferente. Se você tiver muitas variáveis, torna-se difícil visualizar e entender como elas estão relacionadas.



PCA

Principal Component Analysis

Com muitas variáveis, seus dados têm várias "dimensões", e fica complicado perceber padrões ou tendências. Além disso, algumas variáveis podem ser redundantes ou não tão importantes. Trabalhar com todas essas dimensões pode deixar seu modelo de análise mais complexo e lento.





Primeira etapa:

Centralização dos dados

- **Objetivo:** O primeiro passo no PCA é padronizar os dados subtraindo a média e dividindo pelo desvio padrão para cada característica. Isso garante que todas as características estejam na mesma escala:1.
- **Como Fazer:** Para cada variável (coluna) do conjunto de dados, subtraia a média dos valores dessa variável. Isso faz com que a média de cada variável seja zero.




Segunda etapa:

Cálculo Cálculo da Matriz

- **Objetivo:** Entender como as variáveis estão relacionadas entre si, ou seja, como elas "variam juntas".
- **Como Fazer:** Calcule a matriz de covariância ou a matriz de correlação entre as variáveis do conjunto de dados. A matriz de covariância é preferida quando as variáveis estão na mesma escala, enquanto a matriz de correlação é usada quando as escalas são diferentes.



QUANDO USAMOS O PCA É
EXTREMAMENTE RECOMENDADO
QUE OS DADOS ESTEJAM
PADRONIZADOS!





Quarta etapa:

Seleção dos componentes

- **Objetivo:** Reduzir a dimensionalidade do conjunto de dados, mantendo apenas as componentes principais mais importantes.
- **Como Fazer:** Escolha as componentes principais que correspondem aos maiores autovalores. O número de componentes principais a ser mantido depende da quantidade de variação que você deseja preservar (geralmente, um critério comum é manter as componentes que juntas explicam pelo menos 95% da variação).



Quinta etapa:

Projeção dos Dados

- **Objetivo:** Transformar os dados originais nas novas dimensões reduzidas.
- **Como Fazer:** Projete os dados originais nos novos eixos formados pelas componentes principais selecionadas. Isso resulta em um novo conjunto de dados com menos dimensões, mas que retém a maior parte da informação original.