

Explorando os Métodos Ensemble



Acompanhe aqui
os temas que
serão tratados
na videoaula



MÉTODOS DE ENSEMBLE

Métodos de Ensemble são técnicas que combinam vários modelos de aprendizado de máquina para fazer previsões mais precisas e robustas do que qualquer modelo individual.


Imagine um único modelo como uma única pessoa tentando responder uma pergunta. Às vezes, essa pessoa pode errar.

Agora, imagine que várias pessoas estão tentando responder a mesma pergunta. Cada uma pode ter um ponto de vista diferente, e, ao combinar todas as respostas, a chance de chegar a uma resposta correta aumenta.



MÉTODOS DE ENSEMBLE

- **Combinação de Modelos:** Em vez de usar apenas um modelo, usamos vários modelos e combinamos suas previsões.
- **Melhoria da Precisão:** A ideia é que, ao combinar as previsões de vários modelos, podemos reduzir erros e obter uma resposta mais precisa e confiável.




MÉTODOS DE ENSEMBLE



Tipos Comuns:

- **Bagging:** Cria vários modelos a partir de amostras diferentes dos dados e combina suas previsões.
- **Boosting:** Cria uma sequência de modelos, onde cada novo modelo tenta corrigir os erros do anterior.
- **Stacking:** Treina vários modelos e depois usa um "meta-modelo" para combinar as previsões desses modelos.



Métodos de ensemble são como juntar várias opiniões para tomar uma decisão mais precisa. Em vez de confiar em um único modelo, usamos vários modelos para melhorar a acurácia das previsões.




OBJETIVOS



- **Aumentar a Precisão:** Melhorar a acurácia das previsões combinando vários modelos.
- **Reduzir o Overfitting:** Diminuir o risco de um modelo se ajustar demais aos dados de treinamento.
- **Aumentar a Robustez:** Tornar as previsões mais estáveis e confiáveis ao usar diferentes modelos para compensar pontos fracos.

Exemplo



A Random Forest é um método de ensemble que combina muitas árvores de decisão para fazer previsões.

Ao combinar muitas árvores de decisão, a Random Forest melhora a acurácia das previsões. Cada árvore é treinada em uma amostra diferente dos dados, e as previsões são combinadas por votação (para classificação) ou média (para regressão).

Cada árvore de decisão na Random Forest é treinada com um subconjunto dos dados e das características. Isso ajuda a reduzir o risco de uma árvore se ajustar demais aos dados específicos, tornando o modelo