

Boosting: Fundamentos e Aplicações



Acompanhe aqui
os temas que
serão tratados
na videoaula



Boosting

Boosting é uma técnica que melhora a precisão dos modelos de aprendizado de máquina combinando vários modelos simples de forma sequencial, onde cada modelo subsequente tenta corrigir os erros do modelo anterior.




01

Primeira etapa:

Treinamento Inicial

Exemplo: Vamos usar o mesmo conjunto de dados sobre imóveis para prever o preço de venda, mas desta vez com Boosting.

- Modelo Inicial: Começamos treinando um modelo simples, como uma árvore de decisão rasa, em todo o conjunto de dados.




02

Segunda etapa:

Correção de Erros:

Exemplo: Após o modelo inicial fazer suas previsões, identificamos onde ele errou. Suponha que o modelo errou mais em imóveis com características específicas.

- Ajuste dos Erros: O Boosting ajusta o peso dos exemplos que foram mal classificados. Ou seja, dá mais importância aos exemplos que o modelo anterior errou. Por exemplo, se o modelo inicial teve dificuldades com imóveis grandes e caros, esses imóveis receberão um peso maior nas próximas iterações.




03

Terceita etapa:

Treinamento de Novos Modelos:

Exemplo: Um novo modelo é treinado focando nos erros do modelo anterior. Este novo modelo tenta corrigir os erros cometidos pelo primeiro.

- Modelo 2: Treinado com o foco em corrigir os erros do Modelo 1.




04

Quarta etapa:

Combinação de Modelos

Exemplo: Após várias iterações, onde cada modelo novo tenta corrigir os erros dos modelos anteriores, combinamos todos os modelos para fazer a previsão final.

- Pesos dos Modelos: Cada modelo contribui para a previsão final, com modelos mais recentes (que corrigem mais erros) geralmente tendo mais peso.
- Previsão Final: Se a previsão final é uma média ponderada das previsões de todos os modelos, onde os modelos que corrigem mais erros têm maior influência na previsão final.



Resumo: O Boosting treina um modelo inicial e, em seguida, treina modelos adicionais que corrigem os erros do modelo anterior. Cada novo modelo foca nos erros dos modelos anteriores, e todas as previsões são combinadas para obter uma previsão final mais precisa e robusta.



VANTAGENS

- **Alta Precisão:**
- **Boosting pode transformar modelos simples e fracos em modelos fortes, resultando em previsões mais precisas e robustas.**
- **Redução de Viés:**
- **O foco em corrigir os erros dos modelos anteriores ajuda a reduzir o viés, tornando o modelo final mais preciso.**
- **Versatilidade:**
- **Pode ser aplicado tanto em problemas de classificação quanto de regressão.**

EXEMPLOS

- **AdaBoost (Adaptive Boosting):**

Como Funciona: AdaBoost combina vários modelos fracos (geralmente árvores de decisão simples) treinando cada novo modelo para focar nos exemplos que foram mal classificados pelos modelos anteriores.

- **Gradient Boosting:**

Como Funciona: Em cada etapa, um novo modelo é ajustado para os resíduos (erros) do modelo anterior. No final, as previsões de todos os modelos são combinadas.

- **XGBoost (Extreme Gradient Boosting):**

Como Funciona: Uma implementação otimizada e altamente eficiente de Gradient Boosting, muito popular em competições de ciência de dados.