

Gradiente Boosting e Regularização




Acompanhe aqui
os temas que
serão tratados
na videoaula



XGBoost + Regularização

A regularização é uma técnica usada para melhorar a capacidade de generalização de um modelo e evitar o overfitting. Overfitting ocorre quando um modelo aprende muito bem os detalhes e o ruído dos dados de treinamento, mas falha em generalizar para novos dados.



XGBoost + Regularização




Como funciona no XGBoost? O XGBoost incorpora dois tipos principais de regularização: L1 (Lasso) e L2 (Ridge).

- Regularização L1 (Lasso): Adiciona uma penalidade proporcional à soma das magnitudes absolutas dos coeficientes das variáveis. Pode levar a coeficientes zero, o que também ajuda na seleção de variáveis.
- Regularização L2 (Ridge): Adiciona uma penalidade proporcional à soma dos quadrados dos coeficientes das variáveis. Isso ajuda a reduzir a magnitude dos coeficientes e evita que eles se tornem muito grandes, o que pode contribuir para o overfitting.

XGBoost + Parada Antecipada

A parada antecipada é uma técnica usada para interromper o treinamento de um modelo quando o desempenho em um conjunto de validação começa a piorar, mesmo que o número máximo de iterações não tenha sido atingido. Isso ajuda a evitar overfitting e reduz o tempo de treinamento.



XGBoost + Parada Antecipada



Como funciona no XGBoost?

- Conjunto de Validação: Durante o treinamento, o XGBoost avalia o desempenho do modelo em um conjunto de dados separado, chamado de conjunto de validação.
- Monitoramento do Desempenho: O algoritmo monitora a métrica de desempenho (como erro quadrático médio ou acurácia) no conjunto de validação a cada iteração.
- Critério de Parada: Se o desempenho no conjunto de validação não melhorar após um certo número de iterações consecutivas (chamado de "paciente" ou "especificado"), o treinamento é

Importance Features



A importância das features refere-se à medida de quão relevante cada variável (ou característica) é para o modelo na realização de previsões. A avaliação da importância das features ajuda a entender quais variáveis têm mais impacto nas previsões do modelo. A importância das features refere-se à medida de quão relevante cada variável (ou característica) é para o modelo na realização de previsões. A avaliação da importância das features ajuda a entender quais



Importance Features



Atribuição de Pontuação: O XGBoost calcula a importância de cada feature com base em métricas como:

- **Ganância (Gain):** O ganho médio de cada feature quando ela é usada para dividir os dados em árvores. Mede a contribuição da feature para a melhoria na precisão do modelo.
- **Cobertura (Coverage):** A quantidade de amostras de dados que são divididas usando a feature. Mede o impacto da feature na divisão dos dados.
- **Frequência (Frequency):** Quantas vezes a feature é usada para



Passo a Passo



- **Modelo Base:** O modelo começa com uma previsão inicial, que pode ser a média dos valores de resposta no caso de regressão ou a probabilidade base no caso de classificação.
- **Loop de Iterações:** XGBoost realiza uma série de iterações (ou rodadas) para construir um número de árvores especificado (`n_estimators`). Cada iteração adiciona uma nova árvore ao modelo.
- **Resíduos:** Para cada iteração, calcula-se o resíduo, que é a diferença entre os valores reais e as previsões atuais do modelo. O resíduo é a quantidade que o modelo ainda precisa ajustar.

Passo a Passo



Divisão dos Dados: Utilizando os resíduos calculados, uma nova árvore de decisão é construída para prever esses resíduos. A árvore é treinada para minimizar uma função de perda específica (como erro quadrático médio para regressão ou log-loss para classificação).

Critério de Divisão: O XGBoost utiliza um critério de divisão baseado na maximização do ganho (ou redução de erro) em cada divisão de nó da árvore. O ganho é calculado como a diferença na função de perda antes e depois da divisão.

Passo a Passo



Ajuste das Previsões: As previsões do modelo são atualizadas adicionando as previsões da nova árvore ponderada por um fator de aprendizado (`learning_rate`). O fator de aprendizado controla o tamanho do ajuste feito por cada árvore.

Aplicação de Penalidades: Durante o treinamento, o XGBoost aplica penalidades para evitar o overfitting, usando regularização L1 e L2. Isso ajuda a evitar que as árvores se ajustem excessivamente aos dados de treinamento.



XGBoost é um algoritmo de aprendizado de máquina que utiliza técnicas avançadas de boosting com árvores de decisão para criar modelos altamente precisos e eficientes, aplicando regularização e otimização para melhorar a performance e evitar overfitting.