

Criação de Hiperplanos e Regularização



Acompanhe aqui
os temas que
serão tratados
na videoaula




A principal diferença do SVM em relação a outros modelos, como a regressão logística ou redes neurais, é a maneira como ele lida com a separação das classes. Enquanto a regressão logística modela a probabilidade de uma classe, o SVM foca em maximizar a margem entre as classes.

SVM

support vector machine



Nessa aula iremos explorar como é feita a etapa de treinamento do modelo. Entender um pouco mais como é feita a separação dos dados, definição dos vetores e por final as previsões.




01

Primeira etapa:

Criação Hiperplano

Encontrar o hiperplano que maximiza a margem entre as classes. Isso é feito resolvendo um problema de otimização para maximizar a distância entre o hiperplano e os vetores de suporte.

A equação representa um hiperplano em um espaço de características, onde w é o vetor de pesos (ou coeficientes) e b é o viés (ou intercepto). Este hiperplano é o que o SVM tenta encontrar para separar as classes de dados.




02

Segunda Etapa

Erros e Custo

No SVM, o erro é relacionado à quantidade de pontos de dados que são mal classificados ou que estão dentro da margem definida pelo hiperplano. A função de perda do SVM busca minimizar esse erro, mas com uma abordagem diferente do que a maioria dos algoritmos de classificação.

- Em um problema de classificação, o erro é o número de pontos de dados que não são corretamente classificados pelo hiperplano. No entanto, o SVM lida com o erro de uma maneira mais elegante, minimizando não apenas o número de erros, mas também buscando um equilíbrio entre maximizar a margem e minimizar erros.




Punição por classificação Incorreta



No SVM há uma forma de punição por classificações incorretas, que é incorporada na função de perda do modelo.

O parâmetro C controla o trade-off entre a maximização da margem e a penalização de erros de classificação.

Então um valor alto de C penaliza fortemente os erros de classificação, forçando o modelo a se ajustar melhor aos dados de treinamento e potencialmente reduzindo a margem para acomodar menos erros.



Notem que assim como nos últimos modelos, não conseguimos realizar a etapa de aprendizado calculada na mão, como fizemos para regressão, árvore e naive. Devido ao alto nível de complexidade é sempre necessário a utilização de uma linguagem de programação.